

Reporte de Análisis del Dataset CTG (Cardiotocografía)

Práctica 3. Juan Miguel Galan olivares

Este reporte resume el análisis exploratorio realizado sobre el dataset CTG.csv descargado de Kaggle. Incluye una descripción del preprocesamiento, las funciones utilizadas, las visualizaciones más relevantes, así como recomendaciones analíticas para estudios posteriores o modelado predictivo.

Descripción de Funciones Utilizadas

Funciones de Preprocesamiento

1. `completitud_datos(data)`

Esta función recibe un DataFrame de pandas y devuelve, para cada columna, el porcentaje de valores nulos, ordenado de mayor a menor.

Útil para decidir imputaciones o descartar columnas.

2. `check_data_completeness_juan_miguel_galan_olivares(data)`

Mide la completitud global:

- Total de nulos
- Porcentaje por columna de completitud (no nulos)
- Estadísticos de dispersión (solo para columnas numéricas): media, desviación estándar, mínimo, cuartil 1, mediana, cuartil 3 y máximo.

3. `columnas_float_enteras(data)`

Identifica si una columna numérica:

- Tiene solo enteros
- Tiene decimales
- Es mixta

Esto permite seleccionar la estrategia correcta de imputación.

4. `SimpleImputer`

Usado junto con el resultado de la clasificación:

- 'most_frequent': categóricas
- 'median': enteras
- 'mean': decimales

5. `KNNImputer`

Usado para imputar datos faltantes basándose en vecinos.

Recomendado cuando las variables tienen relaciones entre sí (caso de datos médicos).

Funciones de Análisis

6. `detect_outliers(data, methods, z_threshold, iqr_factor, plot)`

Detecta valores atípicos usando:

- IQR (valores fuera de $Q1-1.5IQR$ o $Q3+1.5IQR$), el valor de 1.5 se puede modificar
- Z-score (valores con $|z| > 3$), el valor de 3 se puede modificar

Los outliers detectados simultáneamente por ambos métodos se consideran extremos.

Resultado: se eliminó ~20% del dataset, mejorando la estabilidad del análisis.

7. `clasificar_columnas_continuas_discretas(data)`

Segmenta las columnas en:

- Continuas (>10 valores únicos)
- Discretas
- Alta cardinalidad

Permite elegir correctamente el tipo de visualización.

Funciones de Visualización

Cada una fue diseñada para usarse con cualquier dataset limpio.

Función	Qué hace	Qué gráfica muestra
plot_histograms	Distribución	Histogramas
plot_boxplots	Rangos y outliers	Boxplots
plot_barplots	Frecuencias	Barras
plot_density	Curvas suavizadas	KDE
plot_heatmap	Correlaciones	Heatmap
plot_violins	Distribuciones completas	Violines
plot_lineplots	Tendencias temporales	Líneas
plot_dotplots	Comparación grupos	Dot plots

1. Gráficos de Barras (barplots.py)

`plot_barplots(df, show=True)`

Propósito: Visualizar la frecuencia de categorías en variables discretas.

Funcionamiento:

- Recorre todas las columnas del DataFrame
- Calcula frecuencias con `value_counts()`
- Ordena de menor a mayor frecuencia (ascendente)
- Genera barras horizontales con `plt.barh()`

Cuándo usar: Para comparar categorías y ver cuáles son más/menos frecuentes.

2. Diagramas de Caja (boxplots.py)

`plot_boxplots(df, target_col="NSP", show=True)`

Propósito: Visualizar distribución, mediana, cuartiles y valores atípicos.

Funcionamiento:

- Selecciona solo columnas numéricas con `select_dtypes(include=["number"])`
- Si existe columna objetivo: crea boxplots separados por categoría (agrupados en eje X)
- Si no existe: un boxplot simple por variable
- Usa `sns.boxplot()` de Seaborn

Cuándo usar: Para detectar outliers, comparar distribuciones entre grupos, ver simetría de datos.

3. Curvas de Densidad (density.py)

`plot_density(df, target_col="NSP", show=True)`

Propósito: Mostrar la distribución continua de probabilidad de los datos.

Funcionamiento:

- Verifica que la variable tenga varianza > 0 (evita errores con datos constantes)
- Si varianza = 0: dibuja línea vertical en el valor único
- Si hay varianza: usa `sns.kdeplot()` para curva suave
- Si existe columna objetivo: genera densidades separadas por color (hue)

Cuándo usar: Para ver la forma de distribución (normal, sesgada, bimodal) de manera suave.

4. Dot Plots (dotplot.py)

`plot_dotplots(df, target_col="NSP", show=True)`

Propósito: Comparar distribuciones entre dos grupos mostrando todos los puntos individuales.

Funcionamiento:

- Identifica los 2 grupos más frecuentes de la columna objetivo con `value_counts().index[:2]`
- Filtra el DataFrame para incluir solo esos grupos
- Usa `sns.stripplot()` con jitter (dispersión horizontal) para evitar solapamiento
- Cada punto es una observación individual

Cuándo usar: Para comparar distribuciones entre dos grupos específicos viendo cada dato.

5. Mapas de Calor (heatmap.py)

`compute_spearman_corr(df)`

Propósito: Calcular matriz de correlación de Spearman.

Funcionamiento:

- Selecciona columnas numéricas
- Calcula correlación con `.corr(method="spearman")`
- Spearman mide relación monótonica (no necesariamente lineal)

`plot_heatmap(df, show=True)`

Propósito: Visualizar correlaciones entre todas las variables numéricas.

Funcionamiento:

- Llama a `compute_spearman_corr()` para obtener matriz
- Usa `sns.heatmap()` con:
- `annot=True`: muestra números en cada celda
- `fmt=".2f"`: formato 2 decimales
- `cmap="coolwarm"`: colores azul (negativo) a rojo (positivo)
- `square=True`: celdas cuadradas

Cuándo usar: Para identificar variables relacionadas, multicolinealidad, patrones de correlación.

6. Histogramas (histograms.py)

`plot_histograms(df, target_col="NSP", show=True)`

Propósito: Mostrar distribución de frecuencias en intervalos (bins).

Funcionamiento:

- Selecciona columnas numéricas
- Verifica si `var()` > 0 para decidir si agregar curva KDE
- Usa `sns.histplot()` con:
- `kde=True/False`: curva de densidad superpuesta
- `stat="density"`: normaliza para comparar distribuciones
- `hue=target_col`: separa por colores según categoría objetivo

Cuándo usar: Para ver la distribución de frecuencias, identificar modas, simetría.

7. Gráficos de Líneas (lineas.py)

`plot_lineplots(df, time_col="index", show=True)`

Propósito: Visualizar tendencias temporales o secuenciales.

Funcionamiento:

- Si existe `time_col`: ordena por esa columna y la usa como eje X
- Si no existe: usa el índice del DataFrame
- Genera un gráfico de línea por cada variable numérica

- Usa `ax.plot()` con líneas continuas

Cuándo usar: Para series temporales, tendencias, patrones secuenciales.

8. Gráficos de Violín (`violin.py`)

`plot_violins(df, target_col="NSP", show=True)`

Propósito: Combinar boxplot con curva de densidad para ver distribución completa.

Funcionamiento:

- Usa `sns.violinplot()` con `inner="quartile"` (muestra Q1, Q2, Q3)
- Superpone puntos individuales:
- Si `n_points > 300`: usa `stripplot` (más rápido)
- Si `n_points ≤ 300`: usa `swarmplot` (no solapamiento)
- El ancho del violín representa la densidad de datos

Cuándo usar: Para ver distribución detallada con información de cuartiles y densidad.

Visualizaciones Generadas


Nos enfocaremos en las variables más relevantes: LBE, LB, AC, FM, UC, ASTV, ALTV, Mode, Mean, Variance, con la variable objetivo NSP.

Histogramas de Variables Continuas


Se analizaron las variables continuas, entre ellas ASTV, MSTV, ALTV, MLTV, LB, AC, FM, UC, DL, DP, Mean, Variance, etc.

La mayoría de las variables importantes a analizar tienen distribuciones asimétricas, especialmente las relacionadas con variabilidad.

ASTV y ALTV muestran una gran concentración de valores en rangos bajos para NSP de 1, mientras que las clases patológicas o sospechosas presentan más valores extremos.




En variables de actividad como AC y FM, la mayoría de los registros tienen valores bajos (poca actividad fetal), con algunos casos de actividad elevada.



Curvas de Densidad (KDE)

Estas gráficas suavizan la distribución y permiten comparar visualmente las clases NSP (Normal, Sospechoso, Patológico).

¿Qué se observa?



- Las curvas de las clases normales (NSP=1) están más concentradas.
- Las curvas de la clase patológica (NSP=3) se desplazan hacia valores más altos en variables como ASTV, ALTV y MLTV.


Interpretación:

Las curvas muestran claramente que la variabilidad a corto y largo plazo tiene un patrón distinto en fetos con riesgo.

Boxplots para Identificación de Outliers

Los boxplots permiten identificar valores atípicos y comparar la dispersión entre variables.

¿Qué se observa?



- Variables como ALTV, MLTV, Variance y Mean tienen numerosos valores fuera del rango normal.
- Las desaceleraciones severas (DS) y prolongadas (DP) presentan valores altos asociados con estados patológicos.
- Las cajas (rangos intercuartiles) son más estrechas para la clase normal, indicando menor variabilidad fisiológica.
- NOTA: Estas graficas son después de eliminar los outliers que se mencionan a continuación con Zscore y IQR.

Detección de Outliers

Se detectaron outliers con IQR y Z-score.

Solo los valores detectados por ambos métodos se eliminaron.

Variable	Outliers detectados
AC	35
FM	31
UC	12
MSTV	31
ALTV	57

MLTV	29
DL	24
Max	11
Nmax	11
Mode	36
Mean	17
Median	2
Variance	48

Interpretación

Aproximadamente el 20% de las filas fueron removidas.


Esto mejoró la visualización y redujo el ruido estadístico.

La justificación clínica indica que ciertos valores nunca ocurren en un feto vivo.

Gráficas de Violín

Combinan distribución, densidad y mediana para comparar clases.

¿Qué se observa?



- Las distribuciones de NSP=3 son más anchas y con colas alargadas.
- Las clases normales presentan valores más concentrados y distribuciones más compactas.
- En variables como MSTV y ALTV la separación visual entre clases es particularmente clara.


Interpretación:

Los violines muestran cómo cambia la forma completa de la señal según el estado fetal, haciendo evidente la diferencia entre casos normales y patológicos.

Dotplots (Distribución por Categoría)

Los dotplots muestran cada punto individual agrupado según categorías como NSP o patrones fisiológicos.

¿Qué se observa?



- En variable de varianza, los puntos de NSP=2 tienden a ubicarse en rangos más bajos.
- Algunas variables como Width muestran puntos muy mezclados, lo que indica menor poder predictivo, mientras que se puede ver una concentración para las variables de LB.
- En general, la separación visual sugiere que ciertas variables son más útiles para distinguir clases.


Interpretación:

Los dotplots hacen evidente qué columnas tienen patrones diferenciados entre clases fetales.

Mapas de Calor de Correlación

El heatmap muestra la relación entre todas las variables numéricas.


¿Qué se observa?



Gráficas de Barras (Variables Discretas)

Se graficaron las frecuencias de patrones fisiológicos (A, B, C, D, AD, DE, LD, FS, SUSP), clases (CLASS) y estado fetal (NSP).

¿Qué se observa?



- Algunas categorías como A y B son significativamente más frecuentes.
- La clase NSP está desbalanceada: predominan los casos normales.
- Los patrones FS y SUSP aparecen muy poco, lo que limita su capacidad analítica.


Interpretación:

Existe un desbalance importante que debe considerarse para modelado y análisis descriptivo.

Gráficas de Línea (Secuencia de Observaciones)

Permiten visualizar la variabilidad por índice de fila.

¿Qué se observa?



- Las variables de variabilidad tienen oscilaciones notorias.

Interpretación:

Ayuda a entender la continuidad del dataset y detectar posibles anomalías visuales.

Recomendaciones Analíticas Breves

Calidad de Datos

- La imputación diferenciada funcionó bien: dataset ahora completo.
- Recomendable probar imputación múltiple para análisis clínicos.
- No hay columnas con más del 20% de nulos: buena calidad general.

Selección de Variables

Variables con mayor capacidad diferenciadora para NSP:

- ASTV
- MSTV
- ALTV
- MLTV
- DS
- DP

Estas deben usarse en cualquier modelo.

Modelado

- Aplicar estandarización (StandardScaler).
- Usar validación cruzada estratificada.

Evaluar modelos:

- Logistic Regression
- Random Forest

- XGBoost
- Analizar explicabilidad con SHAP.

Conclusión

El dataset CTG presenta información muy útil para análisis de estado fetal.

Las transformaciones aplicadas:

- Imputación correcta
- Eliminación estructurada de outliers
- Clasificación de variables
- Visualizaciones adecuadas

permitieron identificar patrones clínicos claros, particularmente en las medidas de variabilidad. Este análisis deja un dataset robusto para construir modelos confiables que apoyen decisiones médicas sobre estados fetales sospechosos o patológicos.